

2026 |

ERFOLG VON KAMPAGNEN VORHERSAGEN

| MASCHINELLES LERNEN – SEMESTERPROJEKT

DOZENTEN

Hans-Friedrich Witschel
Manuel Renold

GRUPPE

Gilles Ackermann
Hishor Ramanathan
Sibirnan Gnaneswaren
Varsan Nanendram

EINLEITUNG

Encore Events ist eine Eventagentur, die Marketingkampagnen für verschiedene Veranstaltungen durchführt. Diese Kampagnen laufen über unterschiedliche Kanäle wie Google, Facebook oder Instagram und haben jeweils ein definiertes Budget sowie ein Ziel hinsichtlich der zu erreichenden Impressions.

Eine zentrale Herausforderung besteht darin, frühzeitig zu erkennen, ob eine Kampagne erfolgreich verlaufen wird. Dies ist besonders wichtig, da Kampagnen während ihrer Laufzeit aktiv angepasst werden können. Wenn frühzeitig erkannt wird, dass eine Kampagne ihr Ziel nicht erreichen wird, können beispielsweise Budgeterhöhungen oder zusätzliche Kanäle eingesetzt werden.

Genau hier setzt dieses Projekt an. Ziel ist es, bereits nach der dritten Messung vorherzusagen, ob eine Kampagne am Ende erfolgreich sein wird. Damit kann Encore Events rechtzeitig reagieren und die Effizienz der Kampagnen deutlich verbessern.

Zusätzlich wurde untersucht, ob sich die Problemstellung besser als Klassifikations- oder Regressionsaufgabe eignet.

FORMALISIERUNG DER AUFGABE

Wir modellieren die vorliegende Problemstellung als binäre Klassifikationsaufgabe. Ziel ist es, auf Basis der bis zur dritten Messung verfügbaren Informationen vorherzusagen, ob eine Kampagne am Ende erfolgreich sein wird.

Encore Events möchte dabei nicht wissen, wie viele Impressions am Ende exakt erreicht werden, sondern vielmehr, ob eine Kampagne erfolgreich sein wird oder nicht.

AUFGABENART: BINÄRE KLASSIFIKATION

Eine Kampagne gilt gemäss Aufgabenstellung als erfolgreich, wenn die finalen Impressions mindestens 90 % des definierten Targets erreichen. Diese 90 %-Grenze dient zur Definition der Zielvariable und ermöglicht eine eindeutige Einteilung in zwei Klassen:

„erfolgreich“ (1): finale Impressions $\geq$ 90 % des Targets

„nicht erfolgreich“ (0): finale Impressions $<$ 90 % des Targets

Zusätzlich wurde explorativ auch eine Regressionsaufgabe getestet. Dabei wurde versucht, den prozentualen Zielerreichungsgrad vorherzusagen. Die Resultate der Regression fielen jedoch deutlich schlechter aus als jene der Klassifikation. Deshalb wurde die Klassifikation als finale Modellierungsform gewählt.

Die Klassifikation eignet sich besser, da das eigentliche Ziel der Aufgabenstellung eine Ja-/Nein-Entscheidung über den Kampagnenerfolg ist.

INSTANZEN, ATTRIBUTE UND ZIELVARIABLE

INSTANZEN:

Marketing Kampagne

Die Instanzen des Datensatzes sind einzelne Marketingkampagnen. Jede Kampagne stellt genau eine Beobachtung dar, für die anhand der verfügbaren Informationen eine Vorhersage getroffen wird.

ATTRIBUTE:

Die im Modell verwendeten Attribute basieren auf dem finalen Datensatz nach der Datenaufbereitung in Tableau Prep und der Weiterverarbeitung in Orange.

Bei der Auswahl der Features war neben inhaltlichen Überlegungen auch die begrenzte Datenmenge ein zentraler Faktor. Der finale Datensatz umfasst lediglich rund 230 Werbekampagnen, was im Verhältnis zur Anzahl der ursprünglich verfügbaren Variablen wenig ist. In der Regel wird empfohlen, pro Feature eine ausreichend grosse Anzahl an Beobachtungen zur Verfügung zu haben, damit das Modell die zugrunde liegenden Zusammenhänge zuverlässig erlernen kann. Wird diese Relation nicht eingehalten, steigt das Risiko für Overfitting. Das Modell beginnt dann, zufällige Muster der Trainingsdaten zu memorieren, statt verallgemeinerbare Strukturen zu erkennen. Aus diesem Grund wurde der Featureraum bewusst reduziert, um die Komplexität des Modells in ein gesundes Verhältnis zur verfügbaren Datenmenge zu bringen.

Konkret wurden folgende Variablen bewusst ausgeschlossen:

- *campaign_id wurde nicht als Feature verwendet, da die Variable lediglich der technischen Identifikation dient und keinen inhaltlichen Einfluss auf die Vorhersage besitzt.*
- *impression_4 sowie day_after_4 wurden entfernt, da diese Informationen über den finalen Kampagnenerfolg enthalten würden. Ihre Verwendung würde zu sogenanntem Target Leakage führen.*
- *day_after_1, day_after_2 und day_after_3 wurden ebenfalls ausgeschlossen, da diese Variablen lediglich die Zeitpunkte der Messungen beschreiben und im Modell keinen zusätzlichen Mehrwert lieferten.*
- *Die Variablen start_month, end_month, start_week und end_week wurden im finalen Modell ebenfalls nicht verwendet. In ersten explorativen Analysen waren sie zwar hilfreich zur Untersuchung saisonaler Muster, die Modellleistung verbesserte sich jedoch ohne diese zeitlichen Merkmale.*
- *Die zusätzlich erstellte Variable Marketing_Strategy wurde nur für Visualisierungen verwendet und nicht ins finale Modell übernommen.*

- Auch die Variable seasons wurde lediglich explorativ genutzt und nicht für die finale Modellierung verwendet.

Die Reduktion des Featuresets ist somit nicht nur eine inhaltliche, sondern auch eine statistisch begründete Entscheidung. Gleichzeitig bleibt festzuhalten, dass die geringe Datenmenge eine generelle Einschränkung der Aussagekraft des Modells darstellt. Mit einer grösseren Stichprobe liessen sich vermutlich auch zusätzliche Features sinnvoll integrieren, ohne das Overfitting-Risiko zu erhöhen. Eine Erweiterung des Datensatzes durch Kampagnen aus früheren Jahren wäre daher ein zentraler Hebel, um die Modellqualität in zukünftigen Iterationen weiter zu verbessern.

Die final verwendeten Variablen lassen sich wie folgt einteilen:

Die final verwendeten Variablen lassen sich wie folgt einteilen:

NUMERISCHE ATTRIBUTE

- target
- budget
- days
- impression_1
- impression_2
- impression_3

Diese Variablen ermöglichen es dem Modell, sowohl die bisherige Entwicklung der Kampagne als auch deren Grössenordnung und Dynamik zu berücksichtigen.

KATEGORISCHE ATTRIBUTE:

- region
- category
- facebook
- google_display
- google_search
- instagram

Die Kanalvariablen wurden bereits in Tableau Prep durch eine Pivot-Transformation erzeugt und liegen als binäre Variablen vor. Der Wert 1 bedeutet, dass die Kampagne auf dem jeweiligen Kanal geschaltet wurde.

ZIELVARIABLE/ KLASSENATTRIBUTE:

Die Zielvariable ist success.

Die Zielvariable wurde im Formula-Widget in Orange wie folgt definiert:

- $\text{success} = \text{impression_4} \geq \text{target} * 0.9$

Zusätzlich wurde die Variable `Target_Reached_Pct` berechnet:


- *$\text{Target_Reached_Pct} = \text{impression_4} / \text{target}$*

Diese Variable wurde insbesondere für explorative Analysen sowie die Regression verwendet.

HAUPTTEIL

DATENAUFBEREITUNG

TABLEAU PREP:



Die Datenaufbereitung wurde vollständig in Tableau Prep durchgeführt. Ausgangspunkt waren die drei Tabellen:

- *campaign_basic_information*
- *campaign_channels*
- *campaign_snapshots*

Zunächst wurde sichergestellt, dass *campaign_id* in allen Tabellen denselben Datentyp besitzt. Anschliessend wurden die Tabellen über *campaign_id* miteinander verbunden.

Die Snapshot-Daten lagen ursprünglich in einer langen Struktur vor. Deshalb wurde ein Pivot durchgeführt, sodass separate Spalten entstanden:

- *impression_1* bis *impression_4*
- *day_after_1* bis *day_after_4*

Auch die Kanaldaten wurden transformiert. Die ursprüngliche *n:m*-Beziehung zwischen Kampagnen und Kanälen wurde durch Pivoting in eine flache Struktur überführt. Dadurch entstanden separate binäre Spalten für die einzelnen Kanäle. Technische Duplikate wurden entfernt und unvollständige Datensätze, bei denen der Wert für *impression* fehlte, gelöscht.

Bei der Kategorienspalte zeigten sich zwei Auffälligkeiten:

- Einzelne Werbekampagnen hatten keinen zugewiesenen Kategoriewert. Diese Einträge wurden in die bestehende Kategorie *Others* zugewiesen.
- Innerhalb der Kategorien traten inkonsistente Schreibweisen auf. So existierten beispielsweise sowohl *sport* als auch *Sports* als eigenständige Ausprägungen, obwohl es sich inhaltlich um dieselbe Kategorie handelt.

Solche Varianten wurden vereinheitlicht, sodass alle zugehörigen Datensätze konsistent unter einer einzigen Kategorie geführt werden.

Die Entscheidung, fehlende Werte zu löschen statt zu imputieren, wurde bewusst getroffen, um keine künstlichen Daten durch Schätzungen zu erzeugen.

FEATURE ENGINEERING (ORANGE)

Nach dem Import der Daten in Orange wurde zunächst im Formula-Widget die Zielvariable *success* definiert.

Dabei wird geprüft, ob die final erreichten Impressions mindestens 90 % des Targets erreichen. Ist dies der Fall, wird die Kampagne als „yes“ klassifiziert, ansonsten als „no“.

Zusätzlich wurde die Variable *Target_Reached_Pct* erstellt. Diese beschreibt den prozentual erreichten Anteil des Targets und wurde insbesondere für die explorative Regression verwendet.

Auch wurden zwei weitere Variablen explorativ erstellt:

- *Marketing_Strategy*
- *Seasons*

Die Variable *Marketing_Strategy* fasst die verwendeten Kanäle zu Gruppen zusammen, zum Beispiel *Google_Only*, *Social_Only* und *Mixed*. Dadurch konnte untersucht werden, ob sich unterschiedliche Kanalstrategien in der Zielerreichung unterscheiden.

Die Variable *seasons* wurde aus den Monatsinformationen abgeleitet, um mögliche saisonale Effekte zu untersuchen. Beide Variablen wurden jedoch nicht in das finale Klassifikationsmodell übernommen, sondern nur für explorative Analysen verwendet.

Im Select Columns-Widget wurden anschliessend die finalen Features definiert.

Um Target Leakage zu vermeiden, wurden *impression_4* sowie *day_after_4* ausgeschlossen. Diese Variablen enthalten direkte Informationen über den finalen Kampagnenerfolg und würden das Modell künstlich verbessern.

Die Variablen *day_after_1*, *day_after_2* und *day_after_3* wurden ebenfalls entfernt, da sie keinen relevanten zusätzlichen Informationsgehalt lieferten.

Die finalen Features bestanden aus:

- *impression_1*
- *impression_2*
- *impression_3*
- *target*
- *budget*
- *days*
- *region*
- *category*
- *facebook*
- *google_display*
- *google_search*
- *Instagram*

ALTERNATIVER ANSATZ

Im Rahmen des Feature Engineerings wurde zusätzlich ein alternativer Modellansatz diskutiert, der stärker auf Domain Knowledge Injection setzt. Im Zentrum dieses Ansatzes stand die Idee, sogenannte Phase-Ratios als abgeleitete Features einzuführen. Konkret wären dies die Variablen *Phase_1_Ratio*, *Phase_2_Ratio* und *Phase_3_Ratio* gewesen, jeweils berechnet als prozentualer Anteil der erreichten Impressions am gesetzten Target zum jeweiligen Messzeitpunkt. Eine solche Transformation hätte das Verhältnis zwischen *impression_1* bis *impression_3* und *target* direkt in eine aussagekräftige Kennzahl überführt und damit dem Modell eine inhaltlich relevante Information vorab zur Verfügung gestellt.

Methodisch entspricht ein solches Vorgehen einer Domain Knowledge Injection, bei der bestehendes Fachwissen über die Zusammenhänge in den Daten gezielt in den Featureraum eingebracht wird. Dieser Ansatz ist insbesondere bei kleinen Datensätzen üblich, da das Modell weniger eigenständig erlernen muss und das Overfitting-Risiko reduziert wird.

Ergänzend zu den Phase-Ratios sah der alternative Ansatz auch eine Aggregation weiterer Variablen vor. Statt einzelner binärer Kanalvariablen wie *facebook*, *google_display*, *google_search* und *instagram* wäre die zusammengefasste Variable *Marketing_Strategy* mit den Ausprägungen *Google_Only*, *Social_Only* und *Mixed* verwendet worden. Ebenso wäre die Variable *Seasons* an die Stelle der einzelnen Monatsvariablen getreten, um saisonale Effekte in komprimierter Form abzubilden.

Das resultierende Featureset des alternativen Ansatzes hätte sich wie folgt zusammengesetzt:

- *Days*
- *Region*
- *Category*
- *Phase_1_Ratio*
- *Phase_2_Ratio*
- *Phase_3_Ratio*
- *Marketing_Strategy*
- *Seasons*
- *Budget*

Wir haben uns dennoch bewusst gegen diesen Ansatz entschieden. Ziel war es, ein Modell zu trainieren, das die Zusammenhänge zwischen Impressions, Target und Kampagnenerfolg eigenständig erlernt, ohne durch vorab definierte Verhältnisse oder aggregierte Kategorien in eine bestimmte Richtung gelenkt zu werden. Damit bleibt der Lernprozess offener, und das Modell hat die Möglichkeit, auch nichtlineare oder unerwartete Muster zu identifizieren, die durch eine fixe Ratio-Berechnung oder eine vorab gruppierte Strategievariable nicht abgebildet werden könnten.

Diese Entscheidung ist mit gewissen Trade-offs verbunden. Bei einer kleineren Datenmenge wie der vorliegenden hätte die Domain Knowledge Injection die Modellperformance unter Umständen stabilisiert und das Overfitting-Risiko reduziert. Im Gegenzug erlaubt der gewählte Ansatz eine ehrlichere Bewertung dessen, was das Modell tatsächlich aus den

Daten heraus lernen kann, und liefert damit auch einen authentischeren Erkenntnisgewinn über die zugrunde liegenden Zusammenhänge.


EXPLORATIVE DATENANALYSE

Zur besseren Analyse der Daten wurden verschiedene Visualisierungen eingesetzt, darunter:

- Scatter Plot
- Violin Plot
- Distributions
- Column Statistics
- Rank

Die Analyse zeigte, dass insbesondere die Budgetverteilung stark rechtsschief ist. Die meisten Kampagnen verfügen über eher kleine Budgets, während einige wenige Kampagnen sehr hohe Budgets besitzen. Solche Ausreisser können die Modelle beeinflussen und die Generalisierbarkeit erschweren.

Die Distributions-Analyse bestätigt diese starke Rechtsschiefe der Budgetverteilung. Die meisten Werte liegen im unteren Budgetbereich, während nur wenige Kampagnen sehr hohe Budgets aufweisen. Dadurch können einzelne grosse Kampagnen einen überproportionalen Einfluss auf Modell und Interpretation haben.



Die explorative Analyse zeigte ausserdem Unterschiede zwischen den verschiedenen Marketingstrategien.


Der Violinplot vergleicht die Zielerreichung (*Target_Reached_Pct*) über die drei Marketingstrategien *Google_Only*, *Social_Only* und *Mixed*. Auf der Y-Achse ist der Anteil der erreichten Zielgruppe abgetragen, wobei der Wert 1.0 dem vollständigen Erreichen des Kampagnenziels entspricht.

Am erfolgreichsten schneiden die Kampagnen der Strategie Mixed ab. Ihr Median liegt um den Wert 1.0, und die Verteilung ist breit gefächert mit mehreren Kampagnen, die ihr Ziel deutlich übertreffen. Die Kombination verschiedener Kanäle scheint sich also positiv auf die Zielerreichung auszuwirken.


Die Strategie Social_Only zeigt ebenfalls eine breite Verteilung mit einem Median knapp unterhalb von 1.0. Auch hier gibt es Ausreisser nach oben, allerdings liegt der Schwerpunkt der Kampagnen tiefer als bei Mixed.

Die Gruppe Google_Only umfasst auffällig wenige Datenpunkte und weist eine schmale Verteilung mit einem Median um 0.6 auf. Aufgrund der geringen Fallzahl lassen sich für diese Strategie keine belastbaren Aussagen ableiten. Die Ergebnisse sind hier eher als Hinweis denn als fundierte Schlussfolgerung zu verstehen.

Insgesamt deutet die Analyse darauf hin, dass eine Mischstrategie tendenziell die besten Ergebnisse liefert, während die Bewertung reiner Google-Kampagnen weitere Daten erfordern würde.



Die Scatter-Plot-Analyse zeigte zudem, dass zwischen einzelnen Kanälen und der Zielerreichung keine vollständig klare lineare Trennung sichtbar ist. Es gibt sowohl bei Kampagnen mit als auch ohne Google Search erfolgreiche und weniger erfolgreiche Fälle. Dies spricht dafür, dass der Kampagnenerfolg nicht allein durch einen einzelnen Kanal erklärt werden kann, sondern durch das Zusammenspiel mehrerer Faktoren.



MODELLIERUNG (ORANGE WORKFLOW)

Zur Modellierung wurde in Orange ein Workflow mit mehreren Klassifikations- und Regressionsmodellen aufgebaut.

Für die Klassifikation wurden folgende Modelle getestet:

- *Decision Tree*
- *Random Forest*
- *Gradient Boosting*
- *AdaBoost*
- *Neural Network*


Zusätzlich wurden auch Regressionsmodelle getestet:

- *Linear Regression*
- *Gradient Boosting Regression*
- *Random Forest Regression*

Die Modelle wurden anschliessend im Predictions-Widget zusammengeführt und mit folgenden Widgets evaluiert:

- *Test and Score*
- *Predictions*
- *Confusion Matrix*
- *Rank*
- *Explain Prediction*
- *Tree Viewer*

Der Orange-Workflow ermöglichte dadurch sowohl die quantitative Evaluation als auch die Interpretierbarkeit der Modelle.



EVALUATIONSSTRATEGIE

Für die Evaluation wurde eine stratified 10-Fold Cross Validation verwendet.

Diese Methode reduziert das Risiko zufälliger Verzerrungen und ermöglicht eine robustere Bewertung der Modelle. Bei einer 10-Fold Cross Validation wird der Datensatz in zehn Teile aufgeteilt. Das Modell wird mehrfach trainiert und getestet, wobei jeder Teil einmal als Testmenge verwendet wird.

Durch die stratified Aufteilung bleibt die Klassenverteilung in allen Folds möglichst ähnlich. Dies ist besonders wichtig, wenn die Klassen nicht exakt gleich verteilt sind.

Zur Bewertung wurden mehrere Kennzahlen berücksichtigt:

- AUC (Area Under the ROC Curve)
- CA (Classification Accuracy)
- F1-Score
- Precision
- Recall
- MCC (Matthews Correlation Coefficient)

Die AUC misst die Fähigkeit eines Modells, zwischen erfolgreichen und nicht erfolgreichen Kampagnen zu unterscheiden.

Der F1-Score kombiniert Precision und Recall und eignet sich gut bei leicht unausgeglichenen Klassen.

Besonders wichtig ist der MCC-Wert, da dieser auch bei unausgeglichenen Klassenverteilungen eine robuste Bewertung ermöglicht.

PERFORMANCE SCORE

Die besten Resultate erzielten Gradient Boosting und Random Forest.

Model	AUC	CA	F1	Prec	Recall	MCC
Gradient Boosting	0.857	0.774	0.773	0.774	0.774	0.547
Neural Network	0.743	0.737	0.736	0.738	0.737	0.474
Tree	0.763	0.708	0.706	0.711	0.708	0.417
Random Forest	0.841	0.766	0.766	0.767	0.766	0.532
AdaBoost	0.729	0.730	0.730	0.730	0.730	0.459

Gradient Boosting erreicht mit einem AUC-Wert von 0.857 die beste Trennfähigkeit zwischen erfolgreichen und nicht erfolgreichen Kampagnen. Gleichzeitig erzielt es auch die höchste Classification Accuracy, den höchsten F1-Wert und den höchsten MCC-Wert.

Random Forest schneidet ebenfalls gut ab, liegt aber in allen zentralen Kennzahlen leicht hinter Gradient Boosting. Besonders der MCC-Wert ist bei Gradient Boosting höher, was für eine stabilere Gesamtleistung spricht.

Aus diesem Grund wird Gradient Boosting als bestes Klassifikationsmodell betrachtet.

CONFUSION MATRIX

Die Confusion Matrix zeigt, wie viele Kampagnen korrekt beziehungsweise falsch klassifiziert wurden. Da Gradient Boosting gemäss Performance Score das beste Modell ist, wird insbesondere dieses Modell betrachtet.

Beim Gradient Boosting wurden insgesamt 137 Kampagnen bewertet:

		Predicted		Σ
		no	yes	
Actual	no	61	10	71
	yes	28	38	66
Σ		89	48	137

- 61 Kampagnen korrekt als „no“ klassifiziert
- 38 Kampagnen korrekt als „yes“ klassifiziert
- 10 False Positives erzeugt
- 28 False Negatives erzeugt

Die 10 False Positives bedeuten, dass einige Kampagnen fälschlicherweise als erfolgreich eingeschätzt werden, obwohl sie das Ziel nicht erreichen. Dies ist im Geschäftskontext besonders kritisch, da dadurch potenziell optimierungsbedürftige Kampagnen übersehen werden könnten.

Die 28 False Negatives bedeuten hingegen, dass einige tatsächlich erfolgreiche Kampagnen fälschlicherweise als gefährdet eingestuft werden. Dies kann zu unnötigen Interventionen führen, ist aber weniger kritisch als das Übersehen problematischer Kampagnen.

Insgesamt zeigt die Confusion Matrix, dass Gradient Boosting nicht erfolgreiche Kampagnen besonders zuverlässig erkennt. Gleichzeitig besteht bei erfolgreichen Kampagnen noch Verbesserungspotenzial, da ein Teil davon als „no“ klassifiziert wird.

Zum Vergleich zeigte Random Forest eine schwächere Gesamtleistung in der Confusion Matrix:

- 51 korrekt als „no“
- 43 korrekt als „yes“
- 20 False Positives
- 23 False Negatives

		Predicted		Σ
		no	yes	
Actual	no	51	20	71
	yes	23	43	66
Σ		74	63	137

Damit produziert Random Forest mehr False Positives als Gradient Boosting. Aus geschäftlicher Sicht ist dies ein Nachteil, weil dadurch mehr problematische Kampagnen fälschlicherweise als erfolgreich eingestuft würden.

OVERFITTING UND MODELLQUALITÄT

Die begrenzte Datenmenge von rund 230 Kampagnen in Kombination mit vielen Features bringt grundsätzlich ein erhöhtes Overfitting-Risiko mit sich. Um diesem Risiko entgegenzuwirken, wurden mehrere methodische Massnahmen kombiniert:

- Reduktion des Featuresets auf inhaltlich relevante Variablen
- Einsatz einer stratified 10-Fold Cross Validation für eine realistische Schätzung der Generalisierungsleistung
- Verwendung von Ensemble-Methoden wie Random Forest und Gradient Boosting, die durch Aggregation die Varianz reduzieren

Die vergleichbaren Resultate zwischen den einzelnen Folds deuten auf eine stabile Modellleistung hin und zeigen, dass die Performance nicht stark von der konkreten Aufteilung der Daten abhängt. Das ist ein klares Indiz dafür, dass die getroffenen Massnahmen greifen und das Modell trotz der begrenzten Datenbasis robust generalisiert. Eine grössere Datenbasis würde die Robustheit zusätzlich erhöhen und die methodischen Sicherheitsnetze entlasten.

DATENPROBLEME UND BIAS

Die Analyse der Daten zeigt mehrere potenzielle Herausforderungen.

Einerseits ist die Budgetverteilung stark rechtsschief. Einige wenige Kampagnen besitzen extrem hohe Budgets, während die Mehrheit deutlich kleinere Budgets aufweist. Solche Ausreisser können Modelle stark beeinflussen und zu Verzerrungen führen, insbesondere bei einer kleinen Stichprobe wie der vorliegenden. Ein einzelner extremer Wert hat hier ein deutlich höheres Gewicht, als es bei einem grösseren Datensatz der Fall wäre.


Zusätzlich besteht eine gewisse Unausgeglichenheit zwischen erfolgreichen und nicht erfolgreichen Kampagnen, was die Modellierung zusätzlich erschwert.

Die zentrale Herausforderung liegt jedoch in der generell geringen Datenmenge. Mit rund 200 Datensätzen ist die Basis für belastbare Schlussfolgerungen begrenzt. Das Risiko, vermeintliche Muster zu erkennen, die in Wirklichkeit gar nicht existieren, ist bei einer solchen Stichprobengrösse deutlich erhöht. Mit mehr Datenpunkten würde sich dieses Risiko reduzieren, und Aussagen liessen sich mit höherer Sicherheit treffen.

Ein konkretes Beispiel ist die Beobachtung, dass Kampagnen im Sommer tendenziell schlechter abschneiden und das Ziel seltener erreichen. Verteilt sich der Datensatz auf zwölf Monate, bleiben pro Monat im Schnitt weniger als zwanzig Kampagnen übrig. Auf dieser Basis lässt sich nicht zuverlässig sagen, ob es sich um einen echten saisonalen Effekt handelt oder ob andere Faktoren die Beobachtung erklären. Möglich wäre zum Beispiel, dass die Sommerkampagnen einfach mit einem geringeren Budget ausgestattet waren, eine andere Kategorie bedienten oder weniger Kanäle genutzt haben. Solche Überlagerungen lassen sich bei kleinen Stichproben kaum sauber trennen.

Ein ähnliches Bild zeigt sich bei den Werbekanälen. So performt beispielsweise Google Display deutlich besser als andere Kanäle, allerdings basiert diese Beobachtung auf

lediglich elf Datenpunkten. Ob es sich um einen tatsächlichen Vorteil dieses Kanals handelt oder um einen Zufallseffekt aufgrund weniger erfolgreicher Einzelkampagnen, lässt sich aus den vorhandenen Daten nicht abschliessend beurteilen.



Für künftige Analysen wäre es daher sinnvoll, den Datensatz um Kampagnen aus früheren Jahren zu ergänzen. Eine grössere Datenbasis würde nicht nur die Robustheit des Modells erhöhen, sondern auch die Wirkung einzelner Ausreisser relativieren und differenziertere Aussagen zu saisonalen, kanalspezifischen oder kategoriespezifischen Effekten ermöglichen. Diese Überlegung lässt sich grundsätzlich auf jede Analyse mit beschränkter Datenmenge übertragen.

DETEKTIV-ANALYSE

Für die Detektiv-Analyse wurden insbesondere das Rank-Widget, der Tree Viewer und das Explain-Prediction-Widget verwendet. Das Rank-Widget zeigt, dass vor allem die frühen Impression-Werte für die Vorhersage entscheidend sind.

Die wichtigsten Variablen waren:

- *impression_1*
- *impression_2*
- *impression_3*
- *budget*
- *target*


Damit zeigt sich, dass bereits die ersten drei Messzeitpunkte wichtige Hinweise darauf liefern, ob sich eine Kampagne erfolgreich entwickeln wird.

Auch budget und target sind relevant. Das ist plausibel, da das verfügbare Budget und die Zielgrösse direkt mit der Wahrscheinlichkeit zusammenhängen, ob eine Kampagne ihr Ziel erreichen kann.

Die Kanalvariablen wie instagram, google_display, facebook und google_search hatten im Vergleich dazu einen deutlich geringeren Informationsgehalt.

		#	Info. gain ▾	Gain ratio	Gini
1	N impression_1		0.329	0.165	0.192
2	N impression_2		0.236	0.118	0.151
3	N impression_3		0.222	0.111	0.140
4	N budget		0.133	0.066	0.087
5	N target		0.133	0.066	0.087
6	C category	7	0.120	0.048	0.080
7	C region	7	0.097	0.075	0.056
8	N days		0.030	0.015	0.020
9	C instagram	2	0.008	0.009	0.006
10	C google_display	2	0.007	0.020	0.005
11	C facebook	2	0.006	0.034	0.004
12	C google_search	2	0.003	0.003	0.002

Der Tree Viewer bestätigt diese Beobachtung. Die erste Aufteilung des Entscheidungsbaums erfolgt über impression_1. Danach werden unter anderem impression_2 und category relevant. Dies zeigt, dass frühe Impression-Werte und die Kampagnenkategorie wichtige Hinweise für die Einordnung der Kampagne liefern.



Die Analyse zeigt ausserdem, dass insbesondere Grenzfälle schwierig vorherzusagen sind. Einige Kampagnen weisen nach der dritten Messung bereits gute Werte auf, erreichen das finale Ziel jedoch trotzdem nicht. Andere Kampagnen entwickeln sich erst spät positiv und werden deshalb teilweise fälschlicherweise als gefährdet eingestuft.

BEISPIELANALYSE EINER VORHERSAGE

Zur besseren Interpretierbarkeit wurde das Explain-Prediction-Widget verwendet. Dieses zeigt, welche Variablen besonders stark zur Vorhersage einer Kampagne beitragen.

Im dargestellten Beispiel wurde eine Kampagne mit einer Wahrscheinlichkeit von 97 % als „no“ klassifiziert. Das Modell geht somit mit hoher Sicherheit davon aus, dass die Kampagne das definierte Erfolgsziel nicht erreichen wird.

Der Base Value liegt bei 0.67. Dieser beschreibt die durchschnittliche Ausgangswahrscheinlichkeit der Klasse im Datensatz. Einzelne Variablen verschieben diese Ausgangswahrscheinlichkeit anschliessend nach oben oder unten.

Besonders stark negativ wirkten in diesem Beispiel:

- *days = 128*
- *impression_2 = 2.99e+04*
- *impression_1 = 1.97e+04*


Diese Variablen erhöhten die Wahrscheinlichkeit, dass die Kampagne als „nicht erfolgreich“ klassifiziert wird.

Gleichzeitig gab es auch Faktoren, die dieser Einschätzung teilweise entgegenwirkten:

- *impression_3 = 3.77e+04*
- *category = concert*
- *google_search = 1*
- *google_display = 1*

Diese Variablen wirkten der negativen Einschätzung teilweise entgegen, reichten jedoch nicht aus, um die Gesamtvorhersage zu verändern.

Die Analyse zeigt, dass insbesondere frühe Impression-Werte sowie die Kampagnendauer einen starken Einfluss auf die finale Vorhersage besitzen. Das Explain-Prediction-Widget erhöht zudem die Nachvollziehbarkeit des Modells, da sichtbar wird, welche Faktoren konkret zur Entscheidung beitragen.



REGRESSION

Zusätzlich zur Klassifikation wurde explorativ eine Regression getestet, um den prozentualen Zielerreichungsgrad `Target_Reached_Pct` vorherzusagen.

Dafür wurden drei Regressionsmodelle getestet:

- Linear Regression
- Gradient Boosting Regression
- Random Forest Regression

Im Test-and-Score-Widget ergaben sich folgende Resultate:

Model	MSE	RMSE	MAE	MAPE	sMAPE	R2
Linear Regression	1.952	1.397	0.572	58.887	44.793	-2.173
Gradient Boosting (1)	0.162	0.402	0.271	30.911	26.876	0.737
Random Forest (1)	0.176	0.420	0.283	33.166	27.753	0.713

Die lineare Regression schnitt sehr schwach ab. Der negative R^2 -Wert zeigt, dass dieses Modell die Zielvariable schlechter erklärt als ein einfacher Durchschnittswert.

Gradient Boosting Regression erzielte hingegen mit $R^2 = 0.737$ das beste Regressionsresultat. Auch Random Forest Regression erreichte mit $R^2 = 0.713$ ein brauchbares Ergebnis.

Trotzdem wurde die Klassifikation als finale Modellierungsform gewählt. Der Grund dafür ist, dass die eigentliche Aufgabenstellung keine exakte Schätzung des Zielerreichungsgrads

verlangt, sondern eine klare Entscheidung, ob eine Kampagne erfolgreich sein wird oder nicht. Für den praktischen Einsatz ist diese Ja-/Nein-Entscheidung einfacher interpretierbar und direkter nutzbar.

MODELLWAHL

Als finales Modell wurde Gradient Boosting gewählt.

Gradient Boosting erzielte im aktuellen Modellvergleich die besten Gesamtwerte:

- *AUC = 0.857*
- *CA = 0.774*
- *F1 = 0.773*
- *MCC = 0.547*

Random Forest schnitt ebenfalls gut ab, lag jedoch bei den zentralen Kennzahlen leicht hinter Gradient Boosting:

- *AUC = 0.841*
- *CA = 0.766*
- *F1 = 0.766*
- *MCC = 0.532*

Gradient Boosting erreichte somit nicht nur die beste Trennfähigkeit zwischen den Klassen, sondern auch die höchste Gesamtgenauigkeit und den höchsten MCC-Wert.

Zudem zeigte die Confusion Matrix, dass Gradient Boosting weniger False Positives erzeugte als Random Forest. Dies ist im Geschäftskontext wichtig, da False Positives bedeuten, dass problematische Kampagnen fälschlicherweise als erfolgreich eingeschätzt werden.

Aus diesen Gründen wurde Gradient Boosting als finales Modell ausgewählt.

WIRTSCHAFTLICHER NUTZEN

Das Modell schafft einen klaren wirtschaftlichen Mehrwert, da gefährdete Kampagnen frühzeitig erkannt werden können. Dadurch lassen sich gezielte Massnahmen wie:

- *Budgeterhöhungen*
- *zusätzliche Kanäle*
- *Kampagnenanpassungen*

rechtzeitig umsetzen. Dies ermöglicht einen effizienteren Einsatz der Ressourcen und reduziert Streuverluste im Marketingbudget. Besonders wertvoll ist die Fähigkeit, potenziell problematische Kampagnen bereits nach der dritten Messung zu identifizieren, also zu einem Zeitpunkt, an dem korrigierende Eingriffe noch eine reale Wirkung entfalten können.

GESCHÄFTSMODELL UND FINANZIELLER HEBEL

Da unser Geschäftsmodell vorsieht, dass wir für jede Kampagne, die ihr Target erreicht, einen Bonus von CHF 1'000 erhalten, schlägt sich jede gerettete Kampagne unmittelbar in

zusätzlichen Einnahmen nieder. Der wirtschaftliche Wert des Modells lässt sich damit direkt aus der Anzahl zusätzlich erfolgreicher Kampagnen ableiten.

BEISPIELRECHNUNG ANHAND VON 100 KAMPAGNEN

Zur Veranschaulichung des Mehrwerts wird im Folgenden ein typischer Bestand von 100 Kampagnen betrachtet. In der Vergangenheit zeigt sich, dass ohne gezielte Steuerung rund 31 Kampagnen ihr Target erreichen, während 69 Kampagnen das Ziel verfehlen.

Szenario ohne Modell:

- 31 erfolgreiche Kampagnen
- Bonuseinnahmen: $31 \times \text{CHF } 1'000 = \text{CHF } 31'000$

Szenario mit Modell:

- Das Gradient Boosting Modell erkennt im Testdatensatz rund 86 % der tatsächlich scheiternden Kampagnen korrekt als gefährdet (61 von 71 Kampagnen)
- Auf 100 Kampagnen übertragen werden somit von den 69 gefährdeten Kampagnen rund $69 \times 0.86 = 59$ frühzeitig identifiziert
- Bei einer Interventions-Erfolgsquote von rund 31% können $59 \times 0.31 = 18$ dieser Kampagnen noch zum Erfolg geführt werden
- Erfolgreiche Kampagnen insgesamt: $31 + 18 = 49$
- Bonuseinnahmen: $49 \times \text{CHF } 1'000 = \text{CHF } 49'000$

Mehrwert durch das Modell:

$\text{CHF } 49'000 - \text{CHF } 31'000 = + \text{CHF } 18'000$ zusätzliche Bonuseinnahmen pro 100 Kampagnen

Auf Jahressicht hochgerechnet ergibt sich daraus ein erheblicher finanzieller Effekt, der direkt mit dem Volumen der betreuten Kampagnen skaliert.

BEDEUTUNG DER FALSE NEGATIVES

Aus wirtschaftlicher Sicht besonders kritisch sind die False Negatives. In unserem Fall handelt es sich dabei um Kampagnen, die das Ziel tatsächlich erreicht hätten, vom Modell aber als gefährdet eingestuft wurden. Auf Basis dieser Vorhersage werden zusätzliche Massnahmen ausgelöst, obwohl die Kampagne ihr Ziel auch ohne Eingriff erreicht hätte. Das bedeutet, dass Budget, Werbeplatzierungen und Bewerbungsmassnahmen in Kampagnen fliessen, die diese Unterstützung gar nicht benötigen.

Der Bonus fällt in diesen Fällen zwar weiterhin an, die Marge sinkt jedoch, weil zusätzliche Interventionskosten anfallen, die keinen messbaren Effekt erzielen. Jede Reduktion der False Negative Rate führt damit unmittelbar zu einer höheren Profitabilität pro Bonusauszahlung.

ZUSAMMENFASSUNG DER HEBEL

Der Nutzen des Modells entsteht aus zwei sich ergänzenden Hebeln, die beide direkt auf die Profitabilität wirken:

- *Auf der einen Seite werden zusätzliche Bonuszahlungen generiert, weil rechtzeitig in tatsächlich gefährdete Kampagnen investiert wird.*
- *Auf der anderen Seite werden unnötige Investitionen in Kampagnen reduziert, die ihr Ziel ohnehin erreicht hätten.*

In Summe verschiebt sich dadurch das gesamte Verhältnis zwischen Aufwand und Ertrag deutlich zugunsten des Unternehmens. Vor diesem Hintergrund liegt der Optimierungsfokus für künftige Iterationen des Modells klar darauf, die False Negative Rate weiter zu senken, ohne die Erkennungsleistung bei den tatsächlich gefährdeten Kampagnen zu verschlechtern.

FAZIT

Ziel dieses Projekts war es, mithilfe von Machine Learning vorherzusagen, ob eine Marketingkampagne nach der dritten Messung letztlich erfolgreich sein wird.

Die Aufgabe wurde erfolgreich als Klassifikationsproblem modelliert. Eine Kampagne gilt als erfolgreich, wenn sie mindestens 90 % ihres definierten Targets erreicht.

Die Datenaufbereitung erfolgte vollständig in Tableau Prep sowie Orange. In Tableau Prep wurden die Daten zusammengeführt, bereinigt und durch Pivot-Transformationen in eine modellierbare Form gebracht. In Orange wurden anschliessend die Zielvariable, zusätzliche explorative Features und die finalen Modellvariablen definiert.

Mehrere Klassifikationsmodelle wurden getestet und miteinander verglichen. Dabei erzielte Gradient Boosting die besten Gesamtergebnisse:

- $AUC = 0.857$
- $CA = 0.774$
- $F1 = 0.773$
- $MCC = 0.547$

Random Forest schnitt ebenfalls gut ab, erreichte jedoch in den zentralen Kennzahlen leicht tiefere Werte.

Die Feature-Analyse zeigte, dass insbesondere die frühen Impression-Werte entscheidend für die Vorhersage sind:

- *Impression_1*
- *Impression_2*
- *Impression_3*

Auch budget und target spielten eine wichtige Rolle. Die Kanalvariablen hatten hingegen einen geringeren Einfluss.

Zusätzlich wurde eine Regression getestet. Die lineare Regression war ungeeignet, während Gradient Boosting Regression und Random Forest Regression brauchbare Resultate erzielten. Trotzdem wurde die Klassifikation bevorzugt, da die Aufgabenstellung primär eine Ja-/Nein-Entscheidung über den Kampagnenerfolg verlangt.

Das entwickelte Modell stellt somit ein praxistaugliches Entscheidungssupport-Tool für Encore Events dar. Es ermöglicht eine frühzeitige Einschätzung des Kampagnenerfolgs und unterstützt gezielte wirtschaftliche Interventionen.

Gleichzeitig zeigt die Analyse, dass insbesondere Grenzfälle weiterhin schwierig vorherzusagen sind und weiteres Optimierungspotenzial besteht. Eine grössere Datenbasis würde die Aussagekraft der Modelle weiter erhöhen.

Insgesamt zeigt das Projekt, dass Machine Learning sinnvoll eingesetzt werden kann, um Marketingkampagnen datenbasiert zu überwachen und effizienter zu steuern.